

Respostas às Questões para Discussão

1. Liste as quatro etapas da migração descritas no vídeo de 2018, na ordem em que ocorreram, e explique por que e-mail e filas vieram antes da quebra do monólito.

- **Etapas 1:** Serviços de envio de e-mail.
- **Etapas 2:** Serviços de gestão de filas e mensagens.
- **Etapas 3:** Quebra da plataforma central em microsserviços, migrados um a um.
- **Etapas 4:** Migração do restante de uma só vez devido à insustentabilidade do data center.
- **Por que e-mail e filas vieram antes:** Porque são aplicações *stateless* (sem estado), de baixo risco e falha tolerável. A migração deles serviu como um laboratório de baixo impacto para que a equipe aprendesse a operar na nuvem com segurança, antes de estrangular o monólito principal do negócio.

2. Explique as três condições técnicas que precisam existir para que 60% da capacidade de pico rode em instâncias spot, e relacione cada uma a um mecanismo estudado neste módulo.

1. **Aplicações sem estado (*stateless*):** Os processos não podem salvar dados de negócio na própria máquina, pois se a instância for encerrada pela AWS, os dados não são perdidos.
2. **Orquestrador automatizado:** É necessário um sistema que monitore os avisos de interrupção (de 2 minutos) e recrie automaticamente as instâncias perdidas em novos servidores, sem depender de intervenção humana (Infraestrutura como Código).
3. **Margem de segurança (folga):** A capacidade instalada não pode estar no limite. É preciso ter réplicas suficientes rodando simultaneamente para que a perda repentina de algumas instâncias não derrube o serviço enquanto as substitutas não sobem.

3. Compare as três formas de compra de instância citadas no caso quanto a preço, compromisso e risco de interrupção, e diga qual parcela da curva de demanda cada uma cobre.

- **Instância Reservada:** Tem alto desconto e alto compromisso (contratos de 1 a 3 anos), com risco zero de interrupção. Cobre a **base previsível da demanda** (o vale entre os picos).
- **Instância Sob Demanda:** É a mais cara, não exige compromisso de prazo e não sofre interrupção. Cobre a **folga operacional e o tráfego imprevisto**.
- **Instância Spot:** Possui o maior desconto, sem compromisso de prazo, mas com risco contínuo de interrupção (o provedor pode tomar com 2 minutos de aviso). Cobre a maior parte do **volume no horário de pico**.

4. O caso afirma que a elasticidade permitiu atribuir um custo por pedido. Explique por que essa grandeza não existia no desenho anterior, com infraestrutura em data center próprio. No data center físico, os servidores precisavam ser comprados com capacidade máxima para suportar o pico, mas ficavam ligados e ociosos no resto do dia. O custo da infraestrutura era um bloco mensal fixo que não se dividia pelas vendas. Com a elasticidade da nuvem, a infraestrutura é provisionada apenas em resposta às transações que estão acontecendo. Ao atrelar a capacidade computacional ativamente à demanda do momento, o negócio consegue chegar ao custo unitário exato por pedido.

5. Entre 2018 e hoje, a unidade de escala mudou de instância EC2 para contêiner orquestrado. Descreva o que essa mudança altera na densidade de uso de cada máquina e relacione isso à redução de 40% no custo. Enquanto a máquina virtual (EC2) carrega um sistema operacional pesado para cada aplicação, o

contêiner é muito mais leve e compartilha recursos do hospedeiro. Essa mudança aumenta massivamente a **densidade** da infraestrutura, permitindo "empacotar" muito mais aplicações rodando simultaneamente dentro de um mesmo servidor físico. Ao aproveitar melhor o espaço computacional, o iFood precisou ligar menos servidores para atender a uma demanda ainda maior, o que reduziu seu custo de infraestrutura em 40%.